UNIVERSITÉ ABDELMALEK ESSAÂDI
FACULTÉ DES SCIENCES JURIDIQUES ECONOMIQUES ET SOCIALES
TANGER

Master : Intelligence Artificielle pour l'Economie Numérique et la Gestion

Module : Outils d'analyse des données

Rapport

Projet Décisionnel

Analyse des ventes Amazon

De la donnée brute au tableau de bord décisionnel

Encadrer par : Pr. BENNANI ANAS

Réaliser par : RAFIAI FATIMA

EL OUAHABI Fatima Zohra

Année Universitaire : 2025-2026

Table des matières

Table des matières 1
Introduction générale 3
Présentation du projet 4
Objectifs du projet 4
Présentation des données 5
Caractéristiques générales du dataset 5
Principales colonnes du dataset 5
Problèmes de qualité de données identifiés 5
Réalisation du projet 7
1. Conception du modèle décisionnel 7
2. Mise en place de la base de données (SSMS) 7
3. Construction du pipeline ETL (SSIS) 8
4. Transformation des données dans SSIS (composant Derived Column) 9
5. Exécution du pipeline 11
6. Transformation et peuplement du modèle final (SQL) 12
7. Dimension temporelle simulée 14
8. Restitution avec Power BI — Connexion et modélisation 15
9. Mesures DAX créées 16
10. Page 1 — Vue d'ensemble des ventes 17
11. Page 2 — Analyse produits et clients 18
12. Page 3 — Analyse des remises et performance commerciale 19
Difficultés techniques rencontrées et solutions apportées 20
Problème d'encodage 20
Conflit de types Unicode / non-Unicode 20
Erreur de troncature 20
Doublons de product_id 20
Génération de dates non aléatoires 20
Chemins ambigus dans le modèle Power BI 20
Limites et pistes d'amélioration 21
Conclusion 21

Introduction générale :

Dans un environnement où la prise de décision repose de plus en plus sur l'analyse efficace des données, les systèmes décisionnels, souvent appelés Business Intelligence, sont devenus un pilier fondamental pour le pilotage des organisations. Ces systèmes permettent de transformer des données brutes, souvent dispersées et hétérogènes, en informations claires, structurées et accessibles, qui soutiennent les décisions stratégiques.

C'est dans cette perspective que s'inscrit le projet présenté ici, réalisé dans le cadre d'un module de cours consacré aux systèmes décisionnels. L'objectif est de concevoir une solution complète, depuis l'identification d'une source de données brute jusqu'à la restitution de tableaux de bord interactifs, en passant par la construction d'un pipeline ETL et la modélisation d'un entrepôt de données.

Ce projet répond à quatre exigences principales :

- Le choix d'une source de données brute et imparfaite afin de justifier un vrai travail de nettoyage et de structuration.
- Une mise en place d'un pipeline ETL (Extraction, Transformation, Chargement) avec SQL Server Integration Services (SSIS) pour automatiser l'extraction et la préparation des données.
- La modélisation et le stockage des données selon un schéma décisionnel en étoile dans SQL Server Management Studio (SSMS).
- La restitution des données sous forme de tableaux de bord interactifs avec Power BI, destinés à faciliter le pilotage métier.

Pour mener à bien ce projet, le jeu de données Amazon Sales a été retenu, comprenant des informations sur des produits et des avis clients. Ce dataset présente de nombreuses imperfections typiques des données du monde réel (formats de prix hétérogènes, hiérarchies de catégories mal structurées, doublons, absence de dimension temporelle) ce qui en fait un support pertinent pour appliquer une véritable démarche d'ingénierie de données.

Ce rapport présente, étape par étape, la démarche suivie : de l'analyse initiale du dataset à la construction du pipeline ETL, en passant par la modélisation du schéma en étoile et l'implémentation des tableaux de bord Power BI. Une attention particulière a été portée à la documentation des difficultés techniques rencontrées tout au long du projet, ainsi qu'aux solutions apportées, afin de témoigner d'une compréhension approfondie des outils et des concepts mobilisés.

Présentation du projet :

Ce projet consiste à créer et à mettre en œuvre une solution complète pour la prise de décision. Il est réalisé en équipe de deux personnes. Il couvre toutes les étapes du traitement des données, de l'extraction à partir d'une source brute jusqu'à la présentation sous forme de tableaux de bord interactifs.

Le projet se divise en quatre grandes étapes techniques. Chaque étape utilise un outil différent de l'écosystème Microsoft dédié à la Business Intelligence :

● SQL Server Integration Services (SSIS), qui permet de créer le pipeline ETL (extraction, transformation, chargement) ;

● SQL Server Management Studio (SSMS), qui sert à modéliser et stocker les données selon un schéma décisionnel ;

● Power BI Desktop, qui permet de concevoir des tableaux de bord interactifs utilisés pour le pilotage métier.

Cette méthode permet de reproduire, dans le cadre d'un projet académique, une chaîne décisionnelle proche de celle utilisée dans les entreprises. Les données brutes provenant de systèmes opérationnels doivent être nettoyées, structurées puis présentées de manière claire aux décideurs.

Objectifs du projet :

L'objectif général de ce projet est de mettre en pratique les concepts fondamentaux de l'informatique décisionnelle à travers un cas concret. Plus précisément, ce projet vise à :

- Développer une compétence pratique en ETL en utilisant l'outil professionnel SSIS pour automatiser l'extraction, le nettoyage et le chargement de données brutes ;

- Maîtriser la modélisation dimensionnelle en concevant un schéma en étoile adapté à l'analyse décisionnelle, composé de tables de faits et de dimensions ;

- Développer une rigueur méthodologique sur la qualité des données, en identifiant et en corrigeant les anomalies réelles d'un jeu de données, comme les formats incohérents, les valeurs manquantes, les doublons ou l'encodage ;

- Produire une restitution visuelle pertinente en créant des tableaux de bord Power BI qui répondent à de vraies questions métier ;

- Développer une compétence de résolution de problèmes techniques, car les nombreuses difficultés rencontrées durant le projet ont nécessité une analyse méthodique des causes et l'application de solutions adaptées.

À l'issue de ce projet, l'ambition est d'avoir un système décisionnel fonctionnel et cohérent, qui permet de répondre à des questions d'analyse commerciale comme : quelles catégories de produits génèrent le plus de chiffre d'affaires ? Comment évoluent les ventes au fil du temps ? Quel est le niveau de satisfaction client par catégorie ? Quels sont les produits et clients les plus significatifs ?

Présentation des données :

Le jeu de données que nous l'avons choisi pour ce projet est le dataset « Amazon Sales », que l'on trouve sur Kaggle. Ce dataset rassemble des informations sur les produits vendus sur Amazon en Inde, ainsi que les avis déposés par les clients.

Caractéristiques générales du dataset :

Caractéristique	Détail
Format	Fichier CSV (amazon.csv)
Volume	1 465 lignes
Nombre de colonnes	16
Domaine	Produits et avis clients e-commerce

Principales colonnes du dataset :

Colonne	Description
product_id	Identifiant unique du produit
product_name	Nom du produit
category	Catégorie du produit (hiérarchie empilée)
discounted_price / actual_price	Prix remisé et prix initial
discount_percentage	Pourcentage de remise
rating / rating_count	Note moyenne et nombre d'avis
about_product	Description du produit
user_id / user_name	Identifiant(s) et nom(s) du/des client(s)
review_id / review_title / review_content	Détails de l'avis client
img_link / product_link	Liens vers l'image et la fiche produit

Problèmes de qualité de données identifiés :

Ce jeu de données a été choisi parce qu'il comporte beaucoup d'erreurs, ce qui reflète les difficultés souvent rencontrées avec des données réelles :

Problème	Description
Prix en texte	Symbole monétaire (₹) et séparateurs de milliers (ex. « ₹1,299 »)
Catégories empilées	Une seule colonne category, niveaux séparés par « | »
Avis multiples	Plusieurs user_id / user_name concaténés par virgules
Absence de date	Aucune colonne temporelle dans le dataset source
Doublons	Certains product_id apparaissent plusieurs fois
Encodage	Caractères mal interprétés (ex. « â,¹ » au lieu de « ₹ »)

Ces caractéristiques en font une base de travail particulièrement adaptée à un exercice complet de nettoyage, de transformation et de modélisation décisionnelle.

Réalisation du projet :

Cette section montre, étape par étape, avec des captures d'écran, tout le processus technique que nous avons suivi pour réaliser le projet.

1. Conception du modèle décisionnel :

Un schéma en étoile a été choisi pour sa facilité de lecture et ses bonnes performances dans les analyses décisionnelles. Il se compose d'une table de faits centrale, Fait_Ventes, entourée de quatre tables de dimensions : Dim_Produit, Dim_Categorie, Dim_Client et Dim_Date. Une table supplémentaire, Staging_Amazon, a également été incluse pour stocker les données brutes avant leur transformation.

2. Mise en place de la base de données (SSMS) :

La base de données Amazon_BI a été créée dans SQL Server Management Studio, ainsi que l'ensemble des tables du modèle.

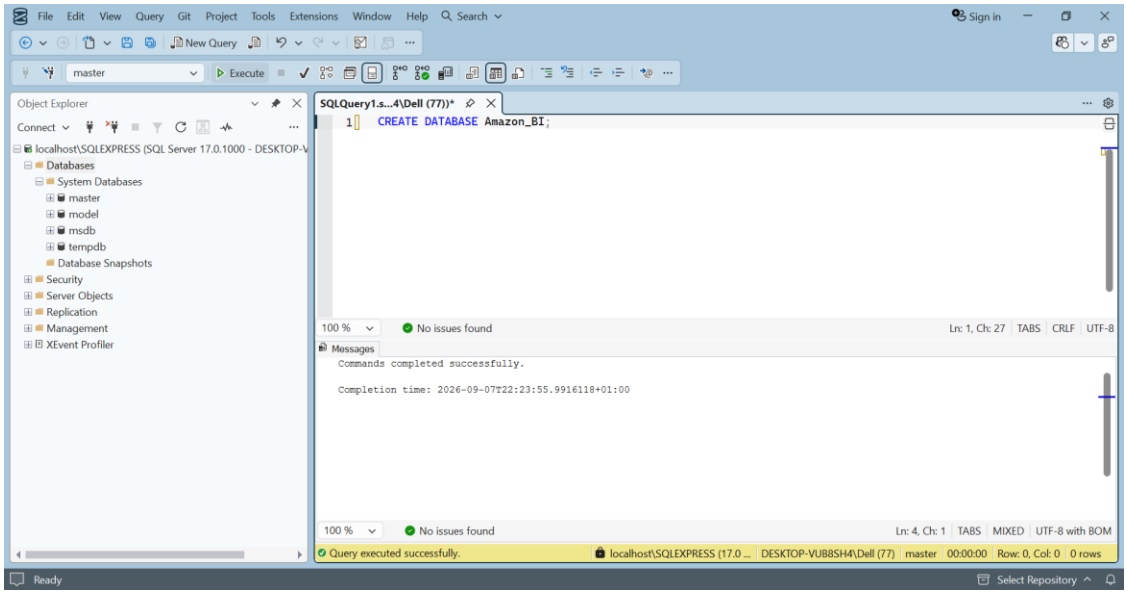


Figure 1 : Création de la base de données Amazon_BI dans SSMS.

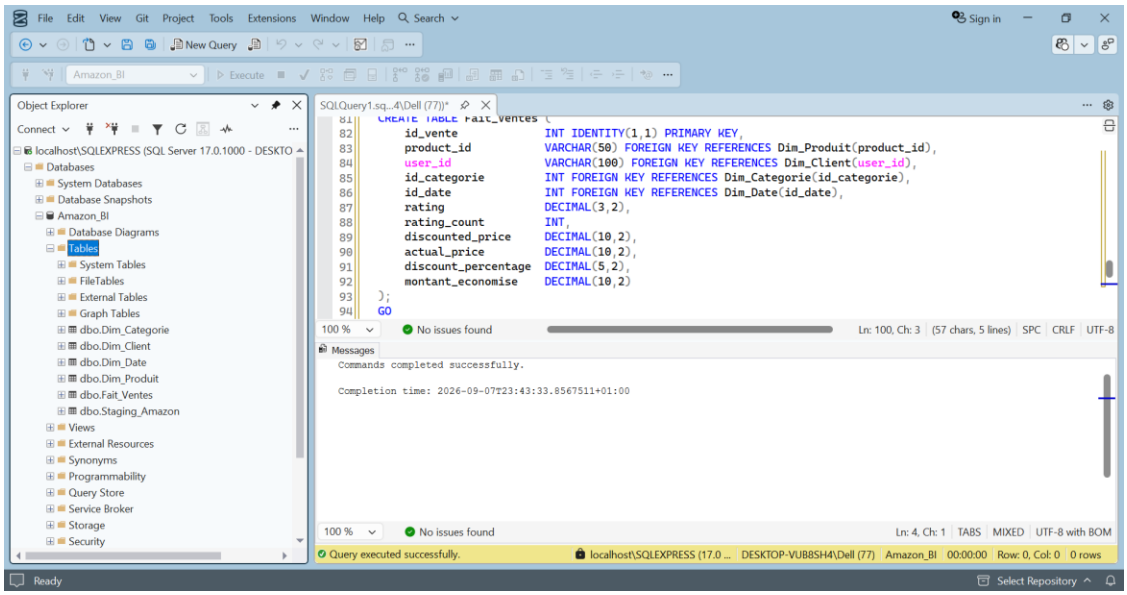


Figure 2 : Création de la table de faits Fait_Ventes ; l'arborescence à gauche confirme la présence des 6 tables du modèle (Dim_Categorie, Dim_Client, Dim_Date, Dim_Produit, Fait_Ventes, Staging_Amazon).

3. Construction du pipeline ETL (SSIS) :

Le pipeline a été créé dans un projet Integration Services (Visual Studio), à l'aide d'une tâche de flux de données contenant trois composants alignés en série : une source de fichier plat, une colonne dérivée, puis une destination OLE DB.

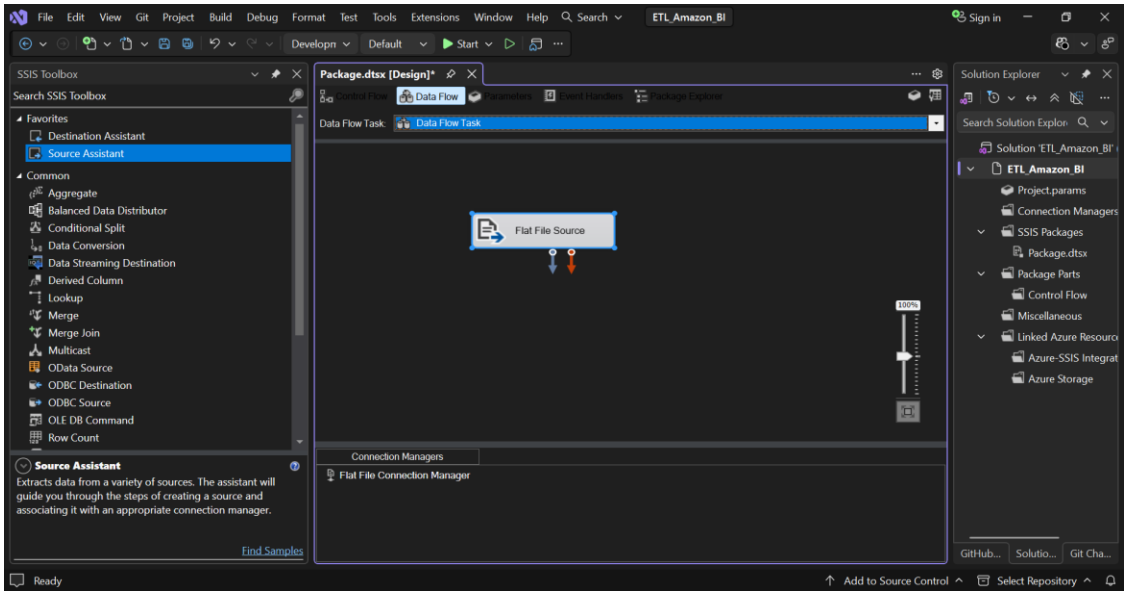


Figure 3 : Configuration du composant Flat File Source, connecté au fichier amazon.csv.

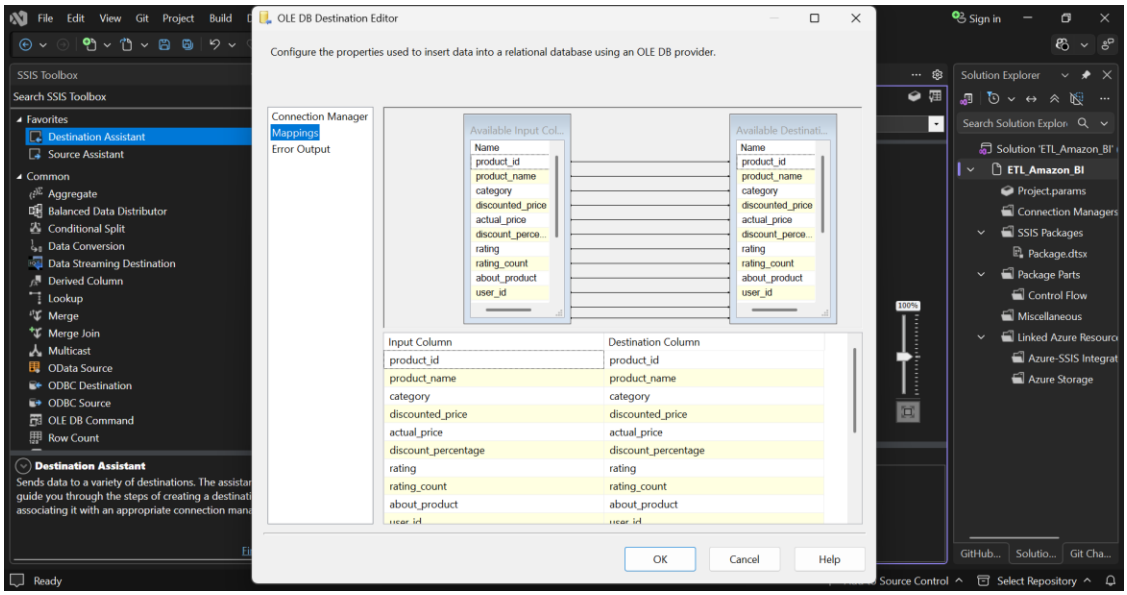


Figure 4 : Premier mapping entre les colonnes source et la table Staging_Amazon (OLE DB Destination).

Analyse : cette première configuration permet un chargement brut du fichier. Pour répondre pleinement à l'exigence ETL mentionnée dans l'énoncé, une étape de transformation a ensuite été intégrée directement dans SSIS.

4. Transformation des données dans SSIS (composant Derived Column) :

Un composant Derived Column a été inséré entre la source et la destination pour nettoyer les données directement dans le pipeline, avant leur chargement :

● discounted_price_clean et actual_price_clean : enlever le symbole monétaire ₹ et les séparateurs de milliers ;

● discount_percentage_clean : enlever le symbole % ;

● rating_clean et rating_count_clean : normaliser les champs numériques.

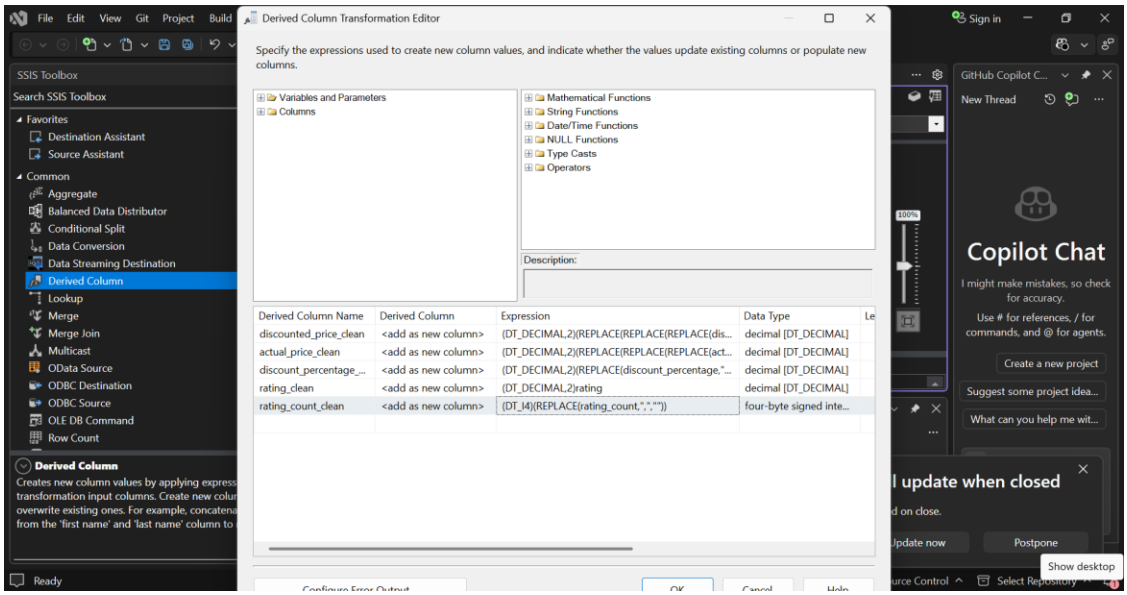


Figure 5 : Configuration du composant Derived Column : expressions de nettoyage des colonnes de prix, pourcentage et note.

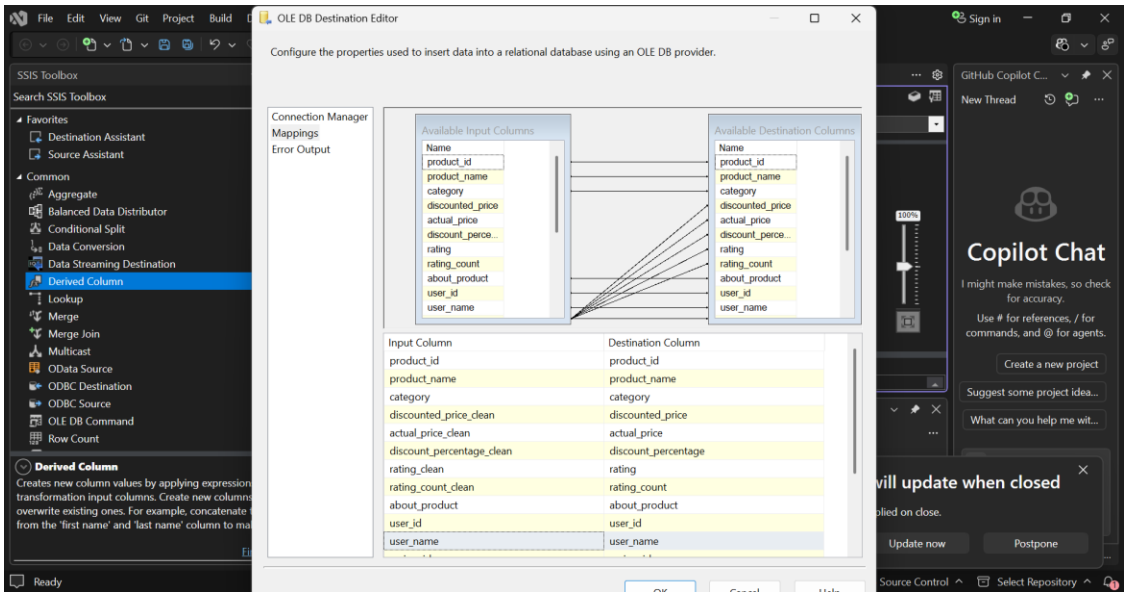


Figure 6 : Mapping final vers Staging_Amazon, utilisant les colonnes nettoyées (discounted_price_clean, actual_price_clean, etc.) plutôt que les colonnes brutes.

5. Exécution du pipeline :

L'exécution du pipeline complet (extraction, transformation et chargement) s'est déroulée avec succès. Les 1 465 lignes du fichier source ont été traitées et chargées dans la table Staging_Amazon, après un nettoyage effectué.

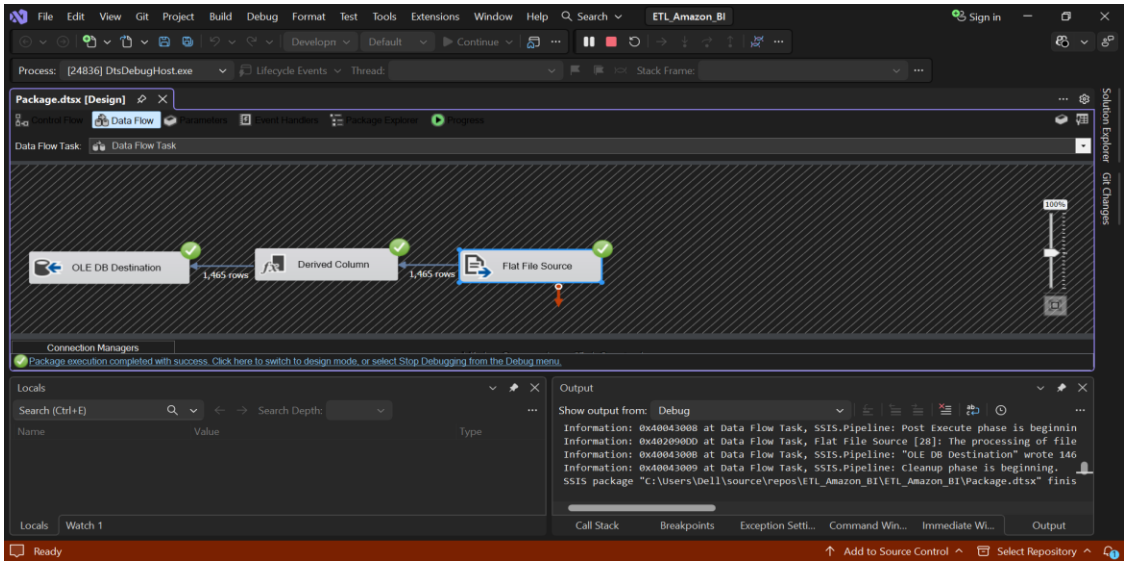


Figure 7 : Exécution réussie du pipeline SSIS : 1 465 lignes traitées à travers Flat File Source, Derived Column et OLE DB Destination.

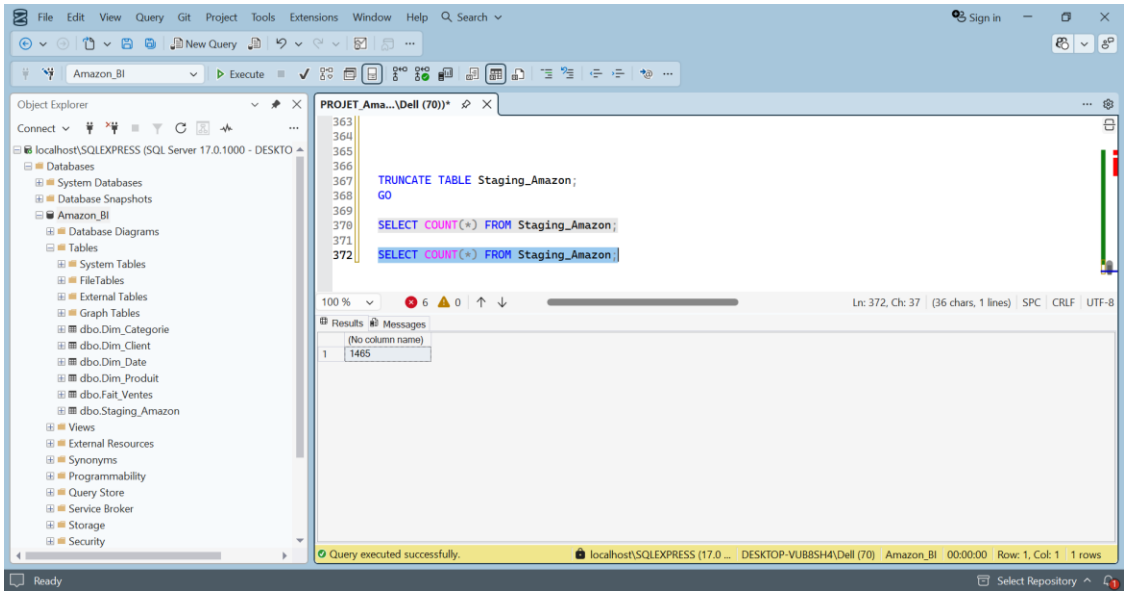


Figure 8 : Vérification dans SSMS : la table Staging_Amazon contient bien 1 465 lignes après rechargement complet.

Analyse : Le fait que le nombre de lignes en sortie, soit exactement 1 465, est strictement identique au nombre de lignes source, ce qui confirme que le système n'a pas perdu aucune donnée durant la transformation.

6. Transformation et peuplement du modèle final (SQL) :

Depuis que la table de staging est désormais nettoyée, des requêtes T-SQL ont été utilisées pour remplir les tables du modèle en étoile. Les dimensions ont été chargées avant les faits afin de respecter les dépendances.

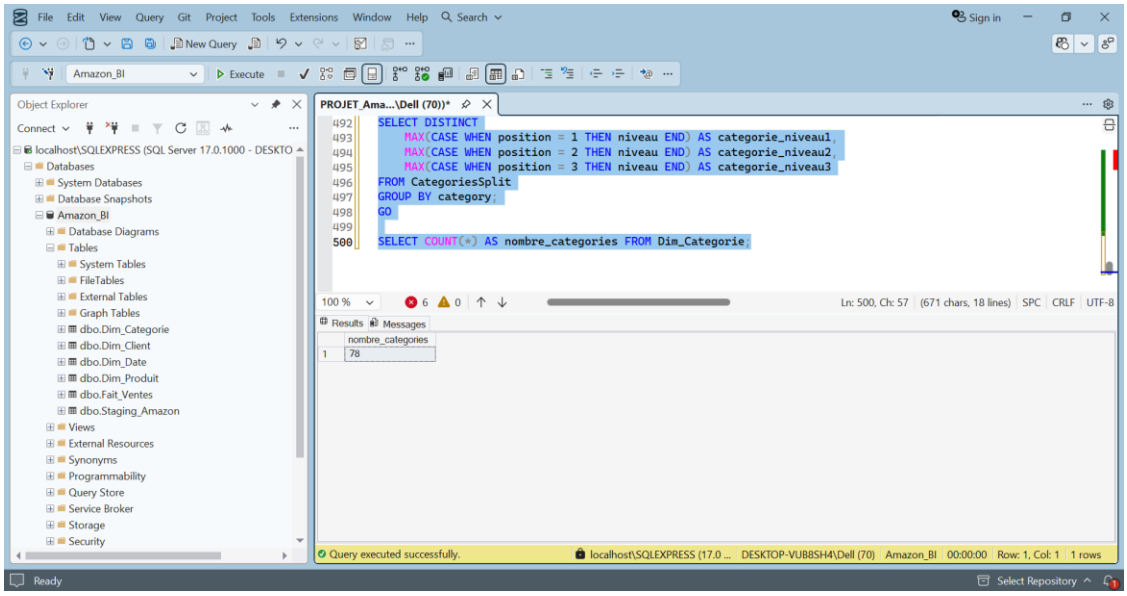


Figure 9 : Peuplement de Dim_Categorie par extraction des niveaux hiérarchiques (STRING_SPLIT sur la colonne category) : 78 catégories uniques obtenues.

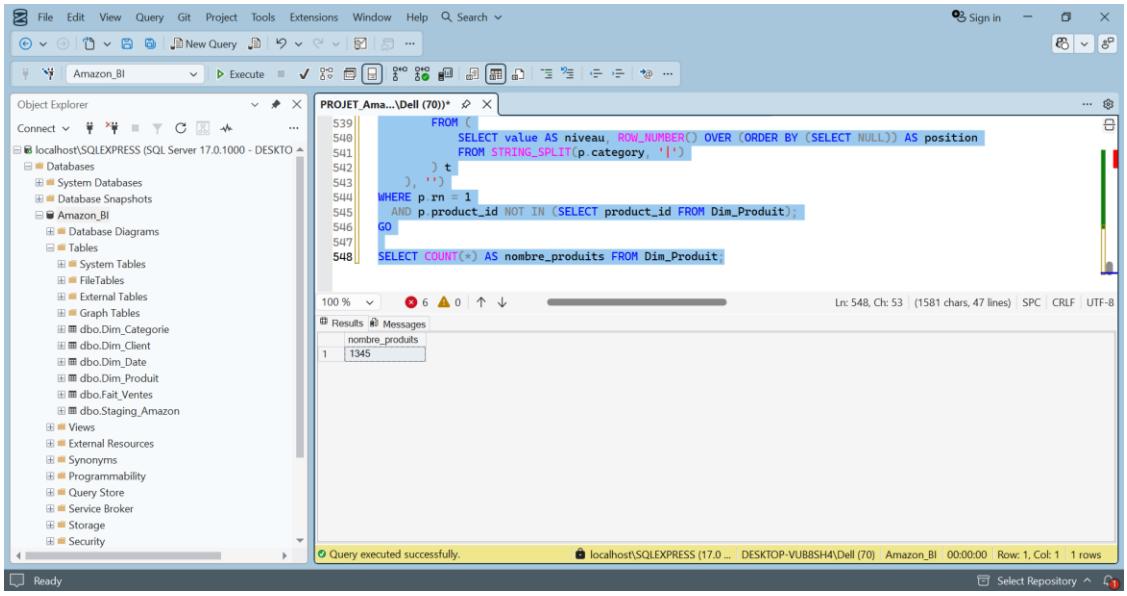


Figure 10 : Peuplement de Dim_Produit avec déduplication (ROW_NUMBER) : 1 345 produits uniques obtenus.

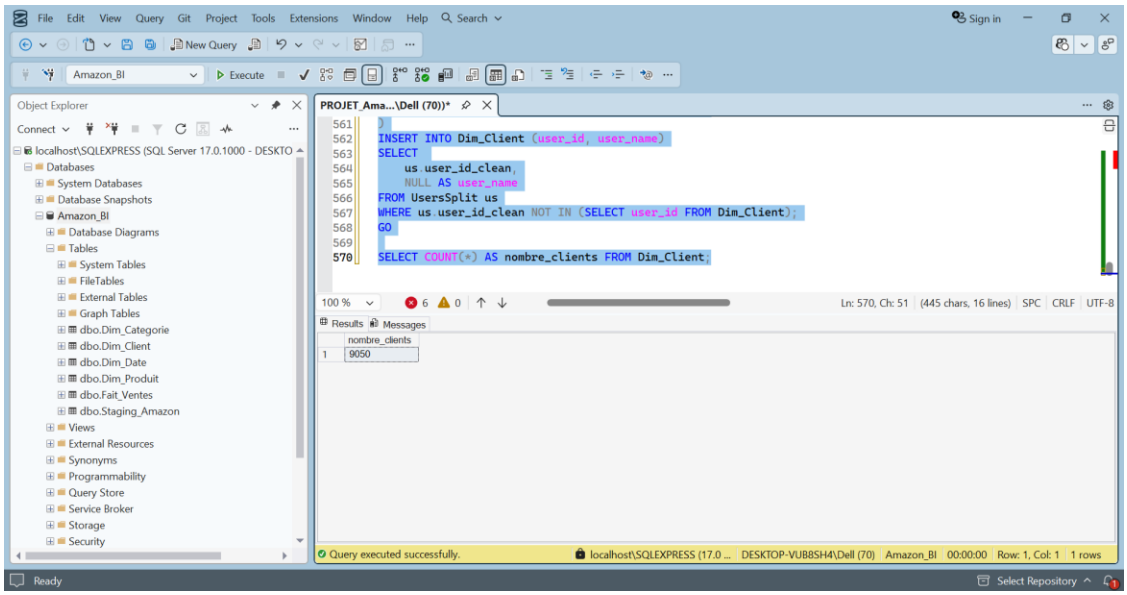


Figure 11 : Peuplement de Dim_Client par séparation des identifiants concaténés (STRING_SPLIT sur user_id) : 9 050 clients uniques obtenus.

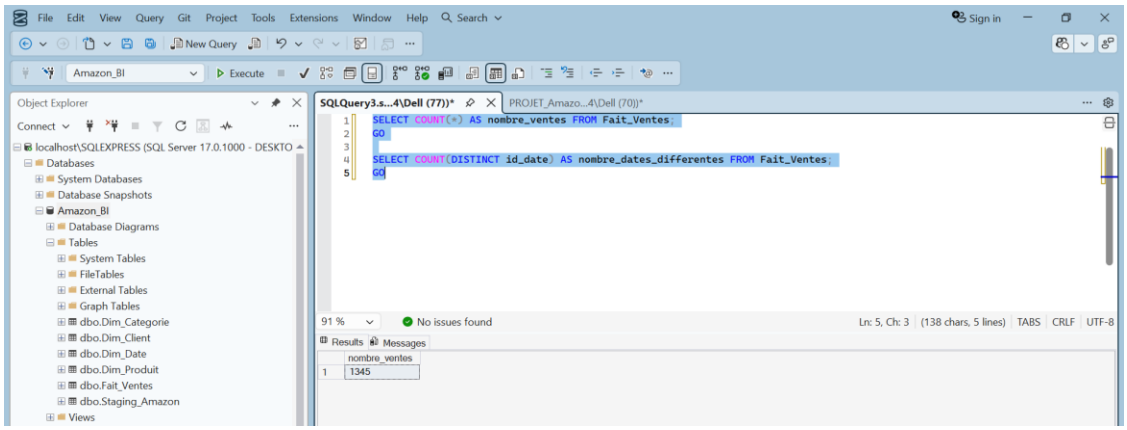


Figure 12 : Peuplement final de Fait_Ventes : 1 345 lignes de faits, cohérentes avec le nombre de produits uniques.

7. Dimension temporelle simulée :

Le dataset source ne contenant aucune information de date, une dimension Dim_Date a été générée pour l'année 2024, et une date a été attribuée aléatoirement à chaque vente.

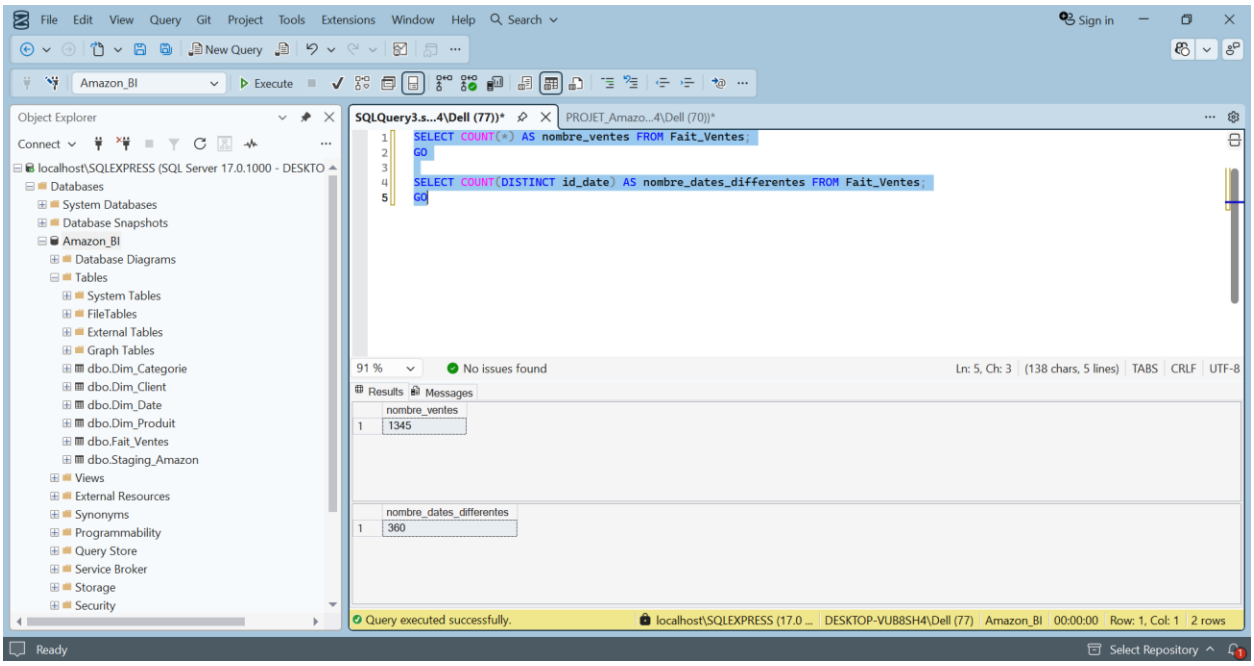


Figure 13 — Attribution d'une date aléatoire à chaque ligne de Fait_Ventes ; vérification du nombre de dates distinctes obtenues.

8. Restitution avec Power BI — Connexion et modélisation :

Power BI Desktop s'est connecté à la base Amazon_BI grâce au connecteur SQL Server, et les six tables du modèle ont été importées.

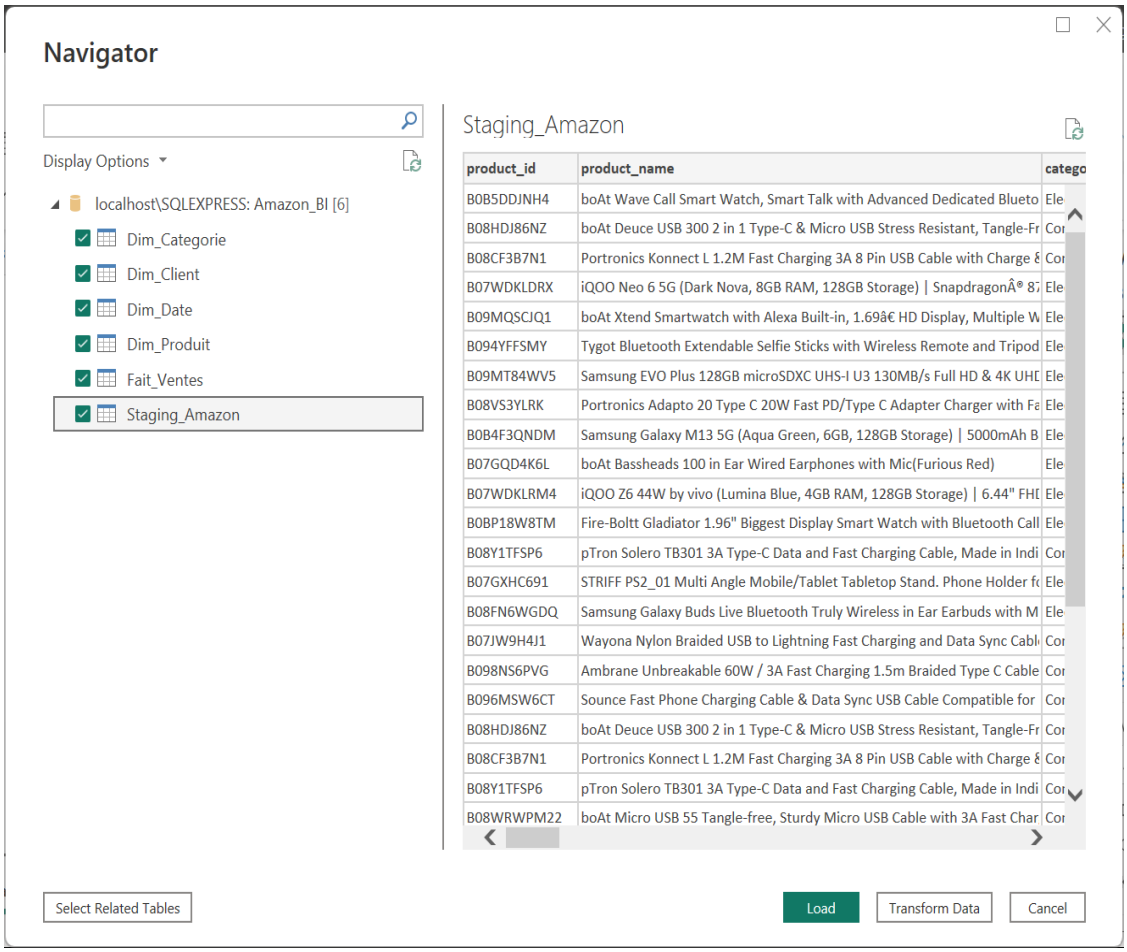


Figure 14 : Sélection des 6 tables du modèle dans le navigateur de connexion Power BI.

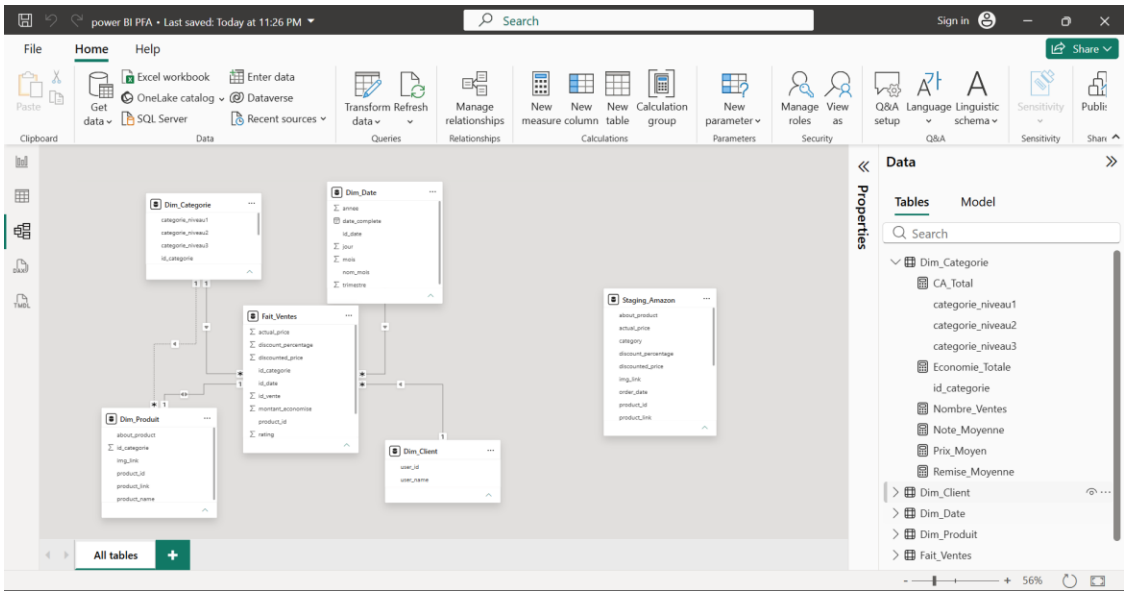


Figure 15 : Vue « Model » de Power BI : schéma en étoile avec Fait_Ventes au centre, relié à Dim_Categorie, Dim_Date, Dim_Produit et Dim_Client ; mesures DAX visibles dans le panneau Data.

9. Mesures DAX créées :

- **CA_Total** = SUM(Fait_Ventes[discounted_price])
- **Note_Moyenne** = AVERAGE(Fait_Ventes[rating])
- **Remise_Moyenne** = AVERAGE(Fait_Ventes[discount_percentage])
- **Nombre_Ventes** = COUNTROWS(Fait_Ventes)
- **Economie_Totale** = SUM(Fait_Ventes[montant_economise])
- **Prix_Moyen** = AVERAGE(Fait_Ventes[discounted_price])

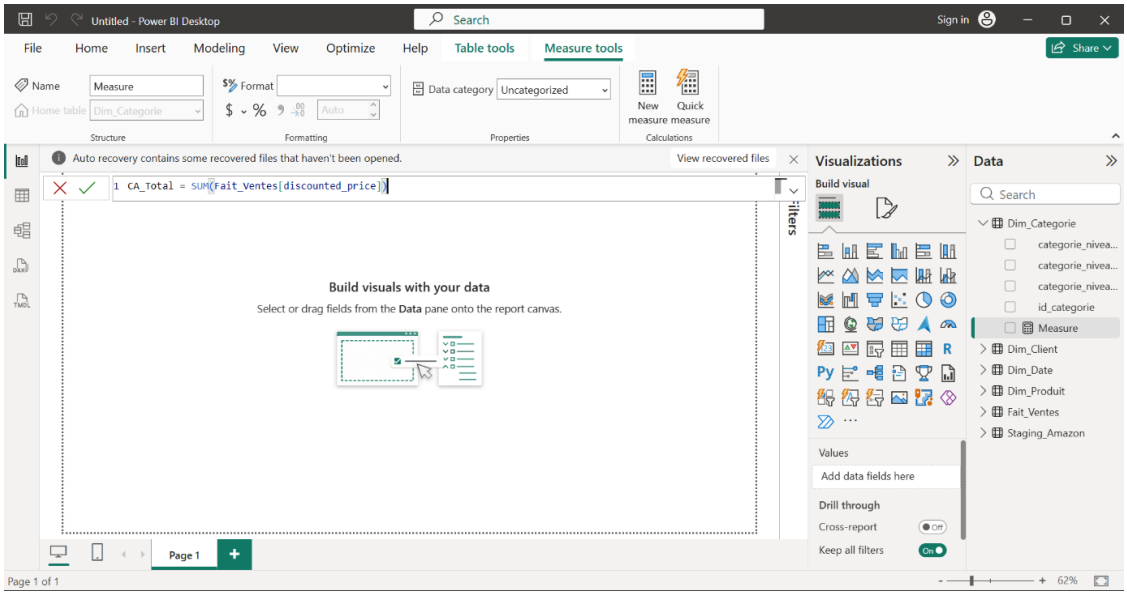


Figure 16 : Création de la mesure CA_Total dans Power BI (éditeur DAX).

10. Page 1 — Vue d'ensemble des ventes :

Cette première page regroupe quatre cartes KPI ainsi qu'une vue synthétique par catégorie et dans le temps.

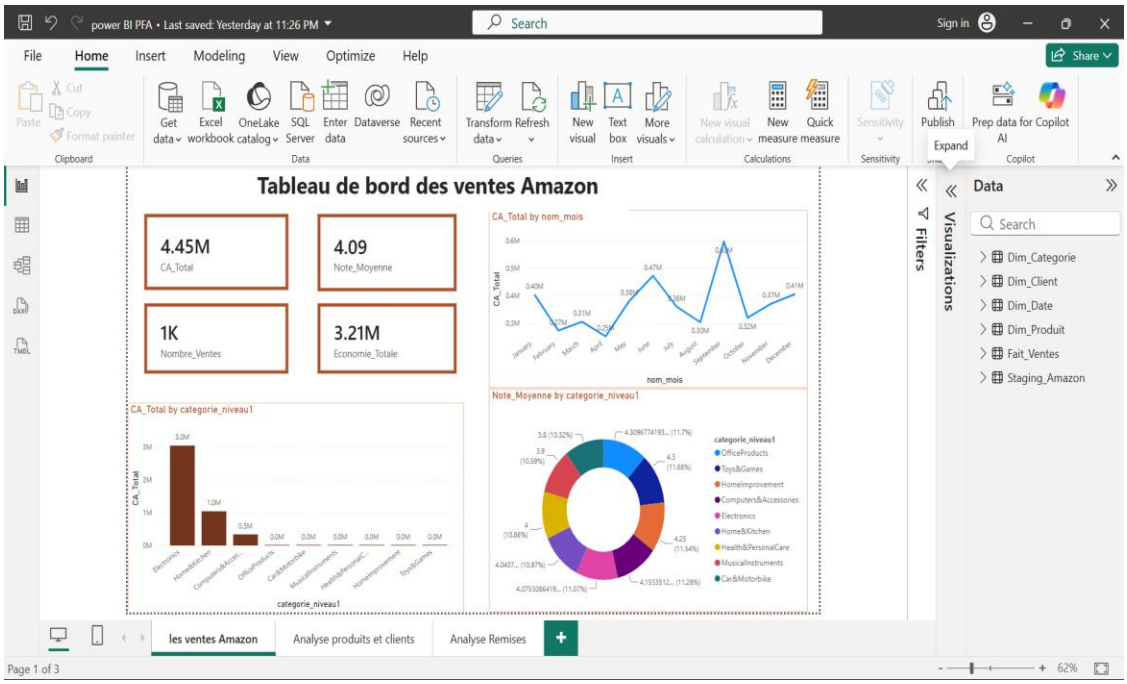


Figure 17 : Page « Les ventes Amazon » : cartes KPI, chiffre d'affaires par catégorie, évolution mensuelle du CA (triée chronologiquement) et satisfaction client par catégorie.

Analyse : le graphique en barres montre une domination claire de la catégorie Electronics dans le chiffre d'affaires total. Cette catégorie est suivie de loin par Home&Kitchen et Computers&Accessories.

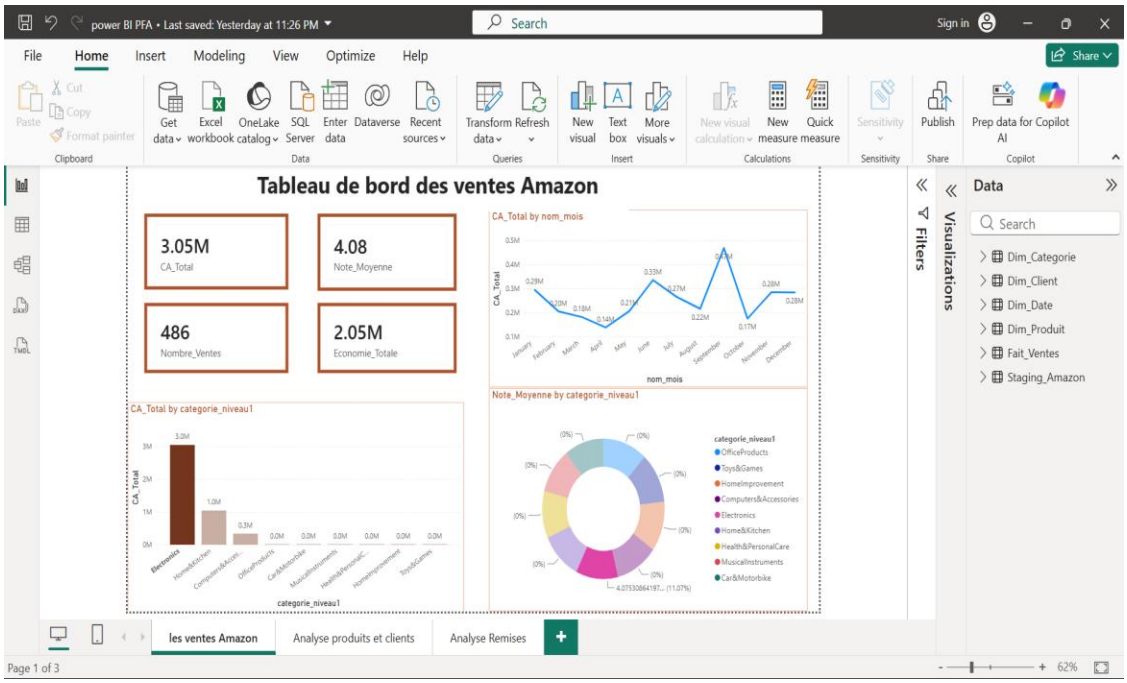


Figure 18 : Démonstration de l'interactivité (cross-filtering) : la sélection de la catégorie « Electronics » met à jour automatiquement l'ensemble des visuels de la page (CA total ramené à 3,05 M, 486 ventes).

11. Page 2 — Analyse produits et clients :

Cette page propose des filtres interactifs (slicers) par catégorie et par mois. Vous pourrez découvrir un graphique des ventes par produit, ainsi que deux tableaux détaillés, l'un consacré aux produits et l'autre aux clients. Chaque tableau dispose d'un filtre Top N.

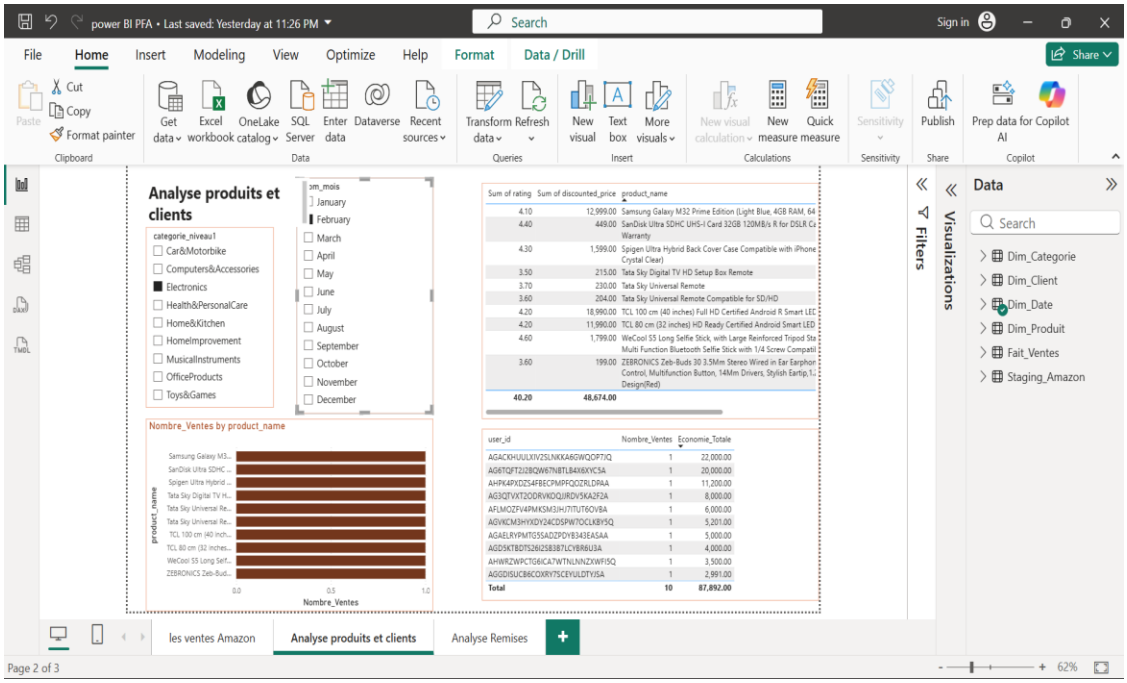


Figure 19 : Page « Analyse produits et clients » : filtres interactifs, graphique des ventes par produit, tableau des 10 produits les plus chers et tableau des 10 clients ayant réalisé le plus d'économies.

12. Page 3 — Analyse des remises et performance commerciale

Cette dernière page se concentre sur l'analyse de la politique de remise : la remise moyenne par catégorie, l'évolution mensuelle des économies des clients, et la distribution des ventes par pourcentage de remise.

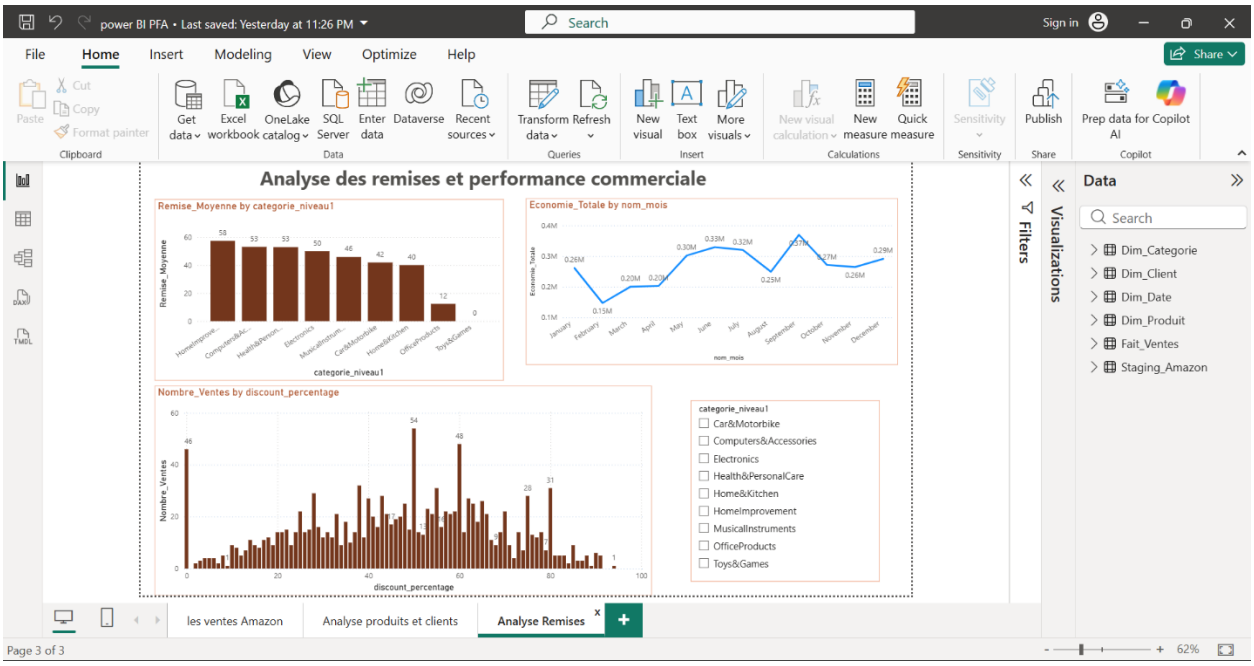


Figure 20 : Page « Analyse des remises et performance commerciale », avec filtre interactif par catégorie.

Difficultés techniques rencontrées et solutions apportées :

Problème d'encodage :

Le symbole monétaire ₹ n'était pas affiché correctement (il apparaissait comme « â,¹ »). Cause : un désaccord entre le Code Page du connecteur Flat File et l'encodage réel du fichier (UTF-8). Solution : modification du Code Page (65001) dans le Flat File Connection Manager.

Conflit de types Unicode / non-Unicode :

Une incompatibilité entre les colonnes texte du fichier CSV et les types NVARCHAR de la table SQL empêchait le chargement des données. Solution : aligner les types de la table Staging_Amazon sur VARCHAR pour résoudre le problème.

Erreur de troncature :

Certains avis clients dépassaient la longueur maximale initialement définie, avec jusqu'à 18 547 caractères pour l'avis client le plus long. Pour résoudre ce problème, nous avons configuré la gestion d'erreur du composant source sur « Ignore failure ».

Doublons de product_id :

On constate que le fichier source contenait des identifiants produits dupliqués.

Norte solution consiste à appliquer une déduplication systématique avec ROW_NUMBER () avant de faire l'insertion dans Dim_Produit et Fait_Ventes.

Génération de dates non aléatoires :

Une première tentative d'attribution de dates aléatoires via une sous-requête simple a produit une seule et même date pour toutes les lignes, SQL Server ayant évalué la sous-requête une seule fois pour l'ensemble du lot. Solution : calcul direct dans la clause SET via CHECKSUM (NEWID ()), garantissant une évaluation ligne par ligne.

Chemins ambigus dans le modèle Power BI :

Lorsque les tables Dim_Produit et Dim_Categorie étaient reliées à la fois directement et indirectement via la table Fait_Ventes, les calculs se répétaient de façon identique sur chaque ligne du même visuel. Pour résoudre ce problème, nous avons désactivé la relation directe entre Dim_Produit et Dim_Categorie et nous avons gardé uniquement le chemin qui passe par la table Fait_Ventes.

Limites et pistes d'amélioration :

● La dimension temporelle (Dim_Date) a été simulée : comme le jeu de données source ne contient aucune information de date, une année complète a été créée et une date aléatoire attribuée à chaque vente.

● La colonne user_name dans Dim_Client n'a pas pu être validée : les champs user_id et user_name sont extraits séparément du fichier source, sans garantie d'ordre fixe, ce qui rend la correspondance incertaine. Par conséquent, les analyses par client reposent sur l'identifiant plutôt que sur le nom.

● Piste d'amélioration : enrichir le modèle avec une dimension géographique réelle, si une source de données supplémentaire est disponible.

Conclusion :

Ce projet a permis de mettre en œuvre, de façon concrète, toute la chaîne décisionnelle : extraction et transformation des données dans un pipeline SSIS, modélisation en schéma en étoile sur SQL Server, puis restitution interactive grâce à Power BI. Les nombreuses difficultés techniques rencontrées et détaillées dans ce rapport ont permis de mieux comprendre le fonctionnement interne de ces outils, notamment la gestion des types de données, des relations et des erreurs de chargement. Ce travail illustre ainsi une démarche complète de projet décisionnel, de la donnée brute jusqu'à la décision. Ce projet a démontré l'efficacité de la chaîne décisionnelle, de la collecte des données à la prise de décision.